

**Преподавание современного ИИ  
на топ-уровне: системное видение**



# Развертывание и эксплуатация систем ИИ

Команда 37 – Прутский А. С., Коржавина А. С., Крид Д. А., Назаров А. Д.,  
Чапкин Н. С., Новиков М. Ю.

# Краткое описание дисциплины

Дисциплина готовит инженеров систем ИИ, смещая фокус с теоретических задач и использования ИИ-инструментов на реальные инженерные решения для бизнеса. Основной упор направлен на развертывание и эксплуатацию ИИ-сервисов в продакшене: совместное использование серверных и локальных моделей для группы пользователей (30+ человек), работа с RAG, управление ресурсами и обеспечение устойчивости под нагрузкой.

Роли:

ML Engineer

MLOps

# Цель

Подготовить специалистов, способных самостоятельно разворачивать, масштабировать и сопровождать системы ИИ в production-среде, с учётом реальных ограничений инфраструктуры, нагрузки и пользовательского опыта.

7 семестр, 72 часа

# Задачи

- Спроектировать архитектуру развёртывания системы ИИ с учётом требований к latency, throughput, отказоустойчивости и стоимости
- Выбрать и обосновать инструменты контейнеризации, оркестрации и сервинга моделей под конкретную задачу
- Развернуть ML-модель в контейнере с поддержкой GPU-ускорения
- Настроить оркестрацию контейнеров в Kubernetes с балансировкой нагрузки
- Организовать хранение и версионирование данных, моделей и артефактов
- Оптимизировать инференс модели методами квантования, компиляции и выбора runtime
- Провести нагрузочное тестирование и измерить ключевые метрики производительности
- Настроить мониторинг, логирование и алертинг для развёрнутой системы

# Задачи

- Реализовать автоскейлинг компонентов системы под изменяющуюся нагрузку
- Построить CI/CD-пайплайн для автоматизации сборки, тестирования и деплоя
- Оценить стоимость и энергопотребление инференса, обосновать выбор инфраструктуры
- Обеспечить безопасность развёрнутой системы: управление секретами, сетевая изоляция, политики доступа
- Интегрировать вспомогательные технологии Big Data в единый стек (стриминг, векторные БД, feature store)
- Развернуть и протестировать систему на различных платформах: on-prem GPU-сервер, облако, edge
- Подготовить техническую документацию: архитектурную схему, runbook, инструкцию по восстановлению

Преподавание современного ИИ на топ-уровне: системное видение

| Элемент дисциплины                                                             | Содержание                                                                                                                                                  | Форма занятия | Объём | Компетенция | Индикатор | Уровень |
|--------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------|-------|-------------|-----------|---------|
| Раздел 1. Архитектура и эксплуатационные требования к промышленным ИИ-системам | Жизненный цикл ИИ-сервиса в проде; SLA/SLO/SLI; метрики эксплуатации (p50/p95/p99, TTFT, TPS, availability); состав production-ИИ-сервиса                   | Л             | 2     | LC-5        | LC-5.1    | С       |
|                                                                                | Формулирование требований к сервису на 30 пользователей; целевые SLO по p95/TTFT/throughput/availability                                                    | ЛР            | 2     | BD-5        | BD-5.3    | П       |
|                                                                                | Анализ архитектур production ИИ-сервисов; подготовка SLA-контракта                                                                                          | СРС           | 2     | BD-5        | BD-5.3    | П       |
| Раздел 2. Контейнеризация и серверы инференса моделей МО                       | Docker/containerd/Podman; образы для ML; NVIDIA Container Toolkit; Triton/TorchServe/TF Serving/vLLM/TGI; continuous batching, paged attention, квантование | Л             | 3     | LC-5        | LC-5.1    | П       |
|                                                                                | Контейнеризация модели; запуск inference-endpoint на CPU и GPU (NVIDIA Container Toolkit); базовые замеры latency/throughput                                | ЛР            | 4     | BD-5        | BD-5.2    | С       |
|                                                                                | Сравнение серверов инференса по критериям; подготовка обоснования выбора                                                                                    | СРС           | 4     | LC-5        | LC-5.1    | С       |

# Преподавание современного ИИ на топ-уровне: системное видение

| Элемент дисциплины                                  | Содержание                                                                                                                         | Форма занятия | Объём | Компет енция | Индик атор | Уровен ь |
|-----------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------|---------------|-------|--------------|------------|----------|
| Раздел 3. Оркестрация и масштабирование ИИ-сервисов | K8s/Docker Swarm/Nomad; Deployment/Service/Ingress; requests/limits; GPU-ноды, taints/tolerations; HPA/VPA; rolling update, probes | Л             | 3     | LC-5         | LC-5.1     | П        |
|                                                     | Развёртывание inference-сервиса в K8s с GPU-ноды; HPA; secrets; rolling update                                                     | ЛР            | 4     | LC-5         | LC-5.1     | П        |
|                                                     | Сравнение оркестраторов; проектирование манифестов; обоснование выбора                                                             | СРС           | 4     | LC-5         | LC-5.1     | С        |
| Раздел 4. Инфраструктура данных и RAG-контуры       | MinIO (S3); DVC; Feast; векторные БД<br>Milvus/Qdrant/Pinecone; Redis; репликация PostgreSQL; RBAC/IAM/ACL; RAG-контур             | Л             | 3     | LC-5         | LC-5.2     | П        |
|                                                     | Сборка RAG-контура (MinIO+Qdrant+Redis); репликация PostgreSQL; контуры read-only/read-write                                       | ЛР            | 4     | LC-5         | LC-5.2     | П        |
|                                                     | Выбор data-стека под тип данных и ограничения; проектирование схемы доступа                                                        | СРС           | 4     | BD-5         | BD-5.1     | С        |

# Преподавание современного ИИ на топ-уровне: системное видение

| Элемент дисциплины                                | Содержание                                                                                              | Форма занятия | Объём | Компет енция | Индик атор | Уровен ь |
|---------------------------------------------------|---------------------------------------------------------------------------------------------------------|---------------|-------|--------------|------------|----------|
| Раздел 5. CI/CD, реестры моделей и GitOps         | GitLab CI/GitHub Actions/ArgoCD/Tekton; пайплайн ML: сборка образов, model registry, GitOps-деплой      | Л             | 2     | LC-5         | LC-5.1     | П        |
|                                                   | Сборка pipeline: образ модели → registry → GitOps-деплой в K8s                                          | ЛР            | 3     | LC-5         | LC-5.1     | С        |
|                                                   | Сравнение CI/CD-платформ; проектирование пайплайна                                                      | СРС           | 2     | BD-5         | BD-5.1     | С        |
| Раздел 6. Мониторинг, логирование и наблюдаемость | Prometheus/Grafana/ELK; метрики инференса (TTFT, inter-token latency, TPS, GPU util); дашборды и алерты | Л             | 3     | LC-5         | LC-5.1     | П        |
|                                                   | Инструментирование сервиса; сбор метрик; построение дашборда и алертов                                  | ЛР            | 4     | BD-5         | BD-5.3     | П        |
|                                                   | Проектирование observability-стека; настройка алертов                                                   | СРС           | 3     | LC-5         | LC-5.1     | П        |

Преподавание современного ИИ на топ-уровне: системное видение

| Элемент дисциплины                                                            | Содержание                                                                                                                                       | Форма занятия | Объём | Компет енция | Индик атор | Уровен ь |
|-------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------|---------------|-------|--------------|------------|----------|
| Раздел 7. Нагрузочное тестирование, устойчивость и оценка качества            | soak/spike/stress; k6/Locust/AB; метрики (p50/p95/p99, throughput, cost/1K req, W/req, GPU util); A/B; chaos engineering                         | Л             | 2     | BD-5         | BD-5.3     | С        |
|                                                                               | Нагрузочный тест профиля «30 пользователей»; A/B двух конфигураций; chaos (kill pod, network partition)                                          | ЛР            | 4     | BD-5         | BD-5.3     | С        |
|                                                                               | Анализ результатов тестирования; рекомендации по оптимизации                                                                                     | СРС           | 3     | BD-5         | BD-5.3     | С        |
| Раздел 8. Планирование мощности, разнородная инфраструктура и итоговый проект | Capacity planning (GPU на 30/1000 пользователей); CPU/GPU/TPU; облако/edge (ONNX, TF Lite, Raspberry Pi); гибрид on-prem GPU + облачный fallback | Л             | 2     | BD-5         | BD-5.2     | П        |
|                                                                               | Финальный проект: сборка shared ИИ-сервиса на 30 человек; SLA- и capacity-отчёт                                                                  | ЛР            | 3     | BD-5         | BD-5.3     | С        |
|                                                                               | Подготовка отчёта и защита итогового проекта                                                                                                     | СРС           | 2     | BD-5         | BD-5.3     | С        |
| ВСЕГО                                                                         |                                                                                                                                                  |               | 72    | Зачет        |            |          |

# Прerequisites

| Дисциплина                             | Сем. | Что даёт для курса                                                    |
|----------------------------------------|------|-----------------------------------------------------------------------|
| Администрирование информационных сетей | 3    | TCP/IP, HTTP, DNS, TLS, балансировка — база для serving и мониторинга |
| Операционные системы                   | 3    | Linux, процессы, systemd, права, CLI — среда развертывания            |
| Обработка данных на Python             | 3    | Python как язык интеграции и скриптов инфры                           |
| Базы данных                            | 4    | SQL, PostgreSQL, транзакции, индексы — data-слой                      |
| WEB-разработка                         | 4    | REST API — интерфейс инференс-сервисов                                |
| Технологии управления данными NoSQL    | 5    | NoSQL, кэши — Redis, векторные БД                                     |
| Технологии создания и поддержки ПО     | 4–5  | Жизненный цикл ПО, основы CI/CD                                       |
| Машинное обучение                      | 5    | Что такое модель, инференс, метрики качества                          |
| Нейросетевые технологии                | 5    | Архитектуры нейросетей, пайплайн обучения                             |
| Глубокое обучение                      | 6    | DL-модели, которые предстоит сервить (LLM и др.)                      |
| MLOps & DevOps                         | 6    | Docker, CI/CD, основы K8s — прямой предшественник                     |
| Микросервисная архитектура             | 6    | Декомпозиция сервисов, оркестрация                                    |
| Технологии тестирования ПО             | 6    | База для k6/Locust, нагрузочного тестирования, SLA                    |
| Технологии обработки больших данных    | 6    | Spark/Flink, дата-инфраструктура                                      |

# Фоновые пререквизиты

| Дисциплина                                     | Сем. | Что даёт для курса                     |
|------------------------------------------------|------|----------------------------------------|
| Основы программирования                        | 1    | База кода                              |
| Алгоритмы и структуры данных                   | 2    | Алгоритмическая база                   |
| Объектно-ориентированное программирование      | 3    | Структура сервисов                     |
| Параллельное и низкоуровневое программирование | 4    | Понимание CPU/GPU/performance          |
| A/B-тестирование и Uplift-моделирование        | 4    | Сравнение конфигураций инференса (A/B) |
| Разработка ИИ-решений для индустрии            | 6    | Прикладной контекст эксплуатации       |

# Пост-реквизиты

| Дисциплина                              | Что развивает поверх курса                                                                         |
|-----------------------------------------|----------------------------------------------------------------------------------------------------|
| Высоконагруженные приложения            | SRE, observability, отказоустойчивость, масштабирование — обобщение с 30 пользователей на highload |
| Генеративный искусственный интеллект    | Прямо использует vLLM/LLM-serving как инфраструктуру                                               |
| Математические модели защиты информации | Защищённый RAG, supply chain, приватность данных                                                   |
| Проектная работа                        | Командный проект — внедрение ИИ-сервиса в эксплуатацию                                             |
| Преддипломная практика                  | Эксплуатация ИИ-системы в реальном контуре                                                         |
| ГИА (госэкзамен + ВКР)                  | Защита решения, включающего production-развертывание ИИ                                            |

| Критерий                   | Описание                                                                                                                 | Множитель (процент участия в оценивании) |
|----------------------------|--------------------------------------------------------------------------------------------------------------------------|------------------------------------------|
| Посещение                  | Отметка о наличии на лекциях и практических занятиях                                                                     | 0                                        |
| Промежуточное тестирование | Тестирование в начале лекции по пройденному материалу                                                                    | 20                                       |
| Лабораторные работы        | Сдача лабораторных работ по курсу                                                                                        | 30                                       |
| Командный проект           | Подготовка и защита командного проекта                                                                                   | 20                                       |
| Зачет                      | Устный ответ на вопросы по дисциплине с использованием примеров.<br>Практическое задание с оценкой существующих решений. | 30                                       |
| Итого                      |                                                                                                                          | 100                                      |

Необходимо набрать 70 баллов

# Спасибо за внимание!

Прутский А.С.  
+7-918-939-20-41

